

Conclusión del Proyecto: Comparación de Modelos de Redes Neuronales Convolucionales para la Clasificación de Imágenes

En este proyecto se evaluaron varias arquitecturas de Redes Neuronales Convolucionales (CNN) para la clasificación de imágenes entre gatos y perros. Los modelos comparados incluyen:

- **Modelo 1:** *MobileNetCNNModificado*
- **Modelo 2:** *MobileNetCNN*
- **Modelo 3:** *AdvancedCNN*
- **Modelo 4:** *ResNet18Modificado*
- **Modelo 5:** *ResNet18*
- **Modelo 6:** *SimpleCNN*

Comparación de Métricas Clave

1. Precisión (Accuracy)

El análisis de precisión en los conjuntos de validación reveló que algunos modelos alcanzaron resultados más altos que otros. Por ejemplo, *MobileNetCNNModificado* alcanzó una precisión cercana al 94%, mientras que *ResNet18Modificado* obtuvo un valor ligeramente mayor, superando el 96%. Por otro lado, modelos como *MobileNetCNN* lograron valores menores, alrededor del 87%, indicando una menor capacidad para capturar las características relevantes de las imágenes. *SimpleCNN* mostró una precisión más estable del 92%, posicionándose como una alternativa fuerte frente a los modelos más complejos.

2. Pérdida

En términos de pérdida, el comportamiento fue similar al de la precisión. *ResNet18Modificado* mostró la pérdida de validación más baja y estable, lo que sugiere que fue capaz de evitar el sobreajuste de manera más efectiva, en comparación con *MobileNetCNNModificado*, que mostró un aumento en la pérdida durante las últimas épocas.

3. Recall y Specificity

En cuanto al *recall*, que mide la capacidad de detectar verdaderos positivos, *ResNet18Modificado* se destacó con un recall superior al 85%, lo que indica una mejor capacidad para identificar correctamente imágenes de gatos y perros. En contraste, *MobileNetCNNModificado* obtuvo un recall más bajo de alrededor del 70%, lo que lo hace menos eficaz en la detección de verdaderos positivos. La *especificidad*, que mide la capacidad de identificar correctamente las imágenes negativas, fue alta en todos los modelos, con valores cercanos al 98%. Sin embargo, el balance entre recall y especificidad favoreció a *ResNet18Modificado*, lo que lo posiciona como un modelo más equilibrado.

4. AUC-ROC

El área bajo la curva ROC (AUC) reflejó que *ResNet18Modificado* obtuvo los mejores resultados con un AUC de 0.95, frente al AUC de 0.92 de *MobileNetCNNModificado*. Este valor más alto de AUC refuerza la robustez de *ResNet18Modificado* en situaciones donde se requiere un equilibrio entre sensibilidad (recall) y especificidad.

5. Sobrecarga Computacional

Aunque *ResNet18Modificado* se destacó en términos de precisión y generalización, es importante señalar que tiene una mayor demanda computacional en comparación con los modelos más simples como *SimpleCNN* y *MobileNetCNN*. Estos últimos ofrecen un rendimiento razonable con una menor complejidad, lo que los hace opciones viables en entornos donde los recursos son limitados.

Conclusión Final

En resumen, *ResNet18Modificado* resultó ser el modelo más robusto y efectivo para la tarea de clasificación de imágenes en este proyecto, destacándose por su precisión, recall y capacidad para evitar el sobreajuste. Aunque *MobileNetCNNModificado* y otros modelos más simples como *SimpleCNN* y *MobileNetCNN* ofrecen un buen rendimiento con menores requisitos computacionales, *ResNet18Modificado* demostró ser más adecuado para aplicaciones donde se requiere una alta precisión y robustez.

Por lo tanto, la elección del modelo dependerá del equilibrio entre la necesidad de precisión y los recursos computacionales disponibles. En entornos donde los recursos son más limitados, *SimpleCNN* y *MobileNetCNNModificado* son alternativas viables, mientras que *ResNet18Modificado* sería la opción preferida para tareas más complejas que requieren una mayor generalización.